

SwarmAlpha：从提示词条件化显式信念到可审计认知治理

多智能体集体决策的测量优先方法与研究白皮书

稿件性质： AAMAS 长文逻辑的中文研究白皮书/论文初稿 版本日期： 2026-08-13 证据状态：
方法与内部重放已实现；测量效度仍在验证；治理效果未建立

摘要

多智能体大语言模型系统既可能整合分散信息，也可能因共同模型偏差、提示词依赖和相互暴露而形成相关错误与虚假共识。一个常见做法是要求 Agent 自报 confidence、概率或 evidence，再据此加权、验证或分配计算预算。但这些字段不是从模型内部状态直接读取的量，而是在特定提示词、信息视图、选项顺序、模型版本和解析规则下生成的协议条件化观测。结构合法、公式可算或记录可重放，均不能单独证明该观测稳定、响应证据、预测结果或适合控制。

本文提出 SwarmAlpha，一种测量优先的多智能体认知治理方法。我们把冻结的 claim 与结果空间、逐字 elicitation contract、模型自报概率、架构记录的 exposure、系统派生量、authorized resolution 和治理状态分层表示，并建立一条权限递增的资格链：结构资格 (Q0)、响应资格 (Q1)、结果资格 (Q2) 和适用域刻画 (Q3)。只有通过相应资格的量，才可以进入 detector development；detector 还须经独立 held-out 验证，才可能触发随机的 apply/sham/holdout 治理行动。治理效果最终由讨论结束后的 private、arm-invariant 概率报告和 proper loss 评价，而不是由共识、verdict 或影响分布代替。

在一个冻结的 80-run 探索实验中，全部 artifact 通过 schema-5 decision replay；154 个注册的首轮显式报告中，142 个合法，valid coverage 为 0.9221。Exact-repeat 配对的 median Jensen-Shannon divergence 为 0.0050，但 P90 为 0.1348，argmax 一致率为 0.7727，因此只能支持初步重复稳定性。K=3 报告的 mean multiclass Brier loss 为 0.9275，ECE 为 0.4046；预置的 certainty $\geq$ 0.7 flag 反而对应更高错误率 (0.7436 对 0.4884)。治理实验仅有 2 个 holdout，按冻结停止规则判为 DEFER_INSUFFICIENT，不能解释为治理有效或无效。这个负结果说明：可审计性是科学推断的必要条件，却不是测量效度或治理效果的替代品。

关键词：多智能体系统；大语言模型；认知治理；测量效度；显式概率报告；校准；因果识别；可重放实验

1. 引言

多 Agent 讨论的直觉很有吸引力：不同实例提出答案、相互批评并修订，或许能够抵消单个模型的盲点。已有研究确实在部分数学、事实与策略任务上观察到收益；但更广泛的比较也发现，多 Agent debate 并不稳定优于 self-consistency 等强单体基线，并且对模型、提示词、轮数和预算十分敏感 [1,2]。在 hidden-profile 任务中，Agent 还必须整合各自私有信息；此时多数意见可能来自共享偏差，而不是独立证据 [3]。因此，“更多 Agent”本身既不是正确性的证明，也不是治理机制。

困难随之从答案聚合转向一个更基础的问题：系统用什么量判断何时应继续讨论、调用验证器、保护少数派或停止计算？现在常见的候选信号包括 verbalized confidence、概率分布、证据条数、一致率和 judge verdict。它们都易于取得，却具有不同的认识论身份。模型输出的 0.8 是一次自报；由概率向量计算的 entropy 是派生描述；prompt 中真正交付给 Agent 的消息是架构遥测；resolved outcome 上的 Brier loss 才是结果量。若把这些对象统称为“信念”或“置信度”，系统就可能用一个尚未验证的观测去决定谁更有发言权，从而把 miscalibration 放大为控制错误。

本文把研究问题压缩为：

在冻结的

claim、信息视图和提示词条件下，LLM

生成的显式概率报告需要通过哪些验证，才有资格进入多智能体诊断与随机治理？

这个问题不预设治理一定有效。相反，治理是资格链末端的被测对象。SwarmAlpha 的贡献有三点。

- 测量对象与权限分层。我们将提示词工件、LLM 自报字段、架构遥测、系统派生量、结果量和潜在构念分开，形式化 prompt-conditioned reported distribution，并给每种量规定允许与禁止的解释。
- 从测量到治理的可审计资格链。我们定义 Q0--Q3 非补偿资格、detector 的 held-out 验证，以及 protocol-arm assignment 与 governance-action assignment 的双层随机化；完整链条以 append-only event、来源 hash、action lifecycle、private outcome 和 deterministic replay 约束。
- 不把工程完整性升级为科学效果。80-run 探索实验显示 schema/replay 全部通过，但 certainty detector 初步反预测，治理主结果因样本不足被预注册规则判为 DEFER。该结果展示了资格链如何撤销未经验证的控制权，而不是展示治理改善。

本文是一篇研究白皮书与论文初稿。当前实证足以说明方法可执行并暴露候选量的问题，但不足以支持通用测量效度、治理效果或异构智能资源配置结论。

2. 相关工作与未解决缺口

2.1 多智能体讨论、聚合与失败

Multi-agent debate 让多个模型实例交换推理并修订答案；ReConcile 进一步结合异构模型与 confidence-weighted voting [1,4]。这些工作回答“某种协议能否提高最终准确率”，但通常不先验证 confidence 是否在该模型、任务和 prompt 下具有稳定含义。系统级失败研究则归纳了验证失败、角色错配和终止问题，表明过程分析不能只看最终答案 [5]；failure taxonomy 的存在仍不自动提供有效 detector 或干预。

通信拓扑研究还表明，Agent 实际看到哪些消息会改变协作表现 [6]。因此 exposure 不是日志中的附属字段，而是实验处理的一部分。仅从最终 transcript 反推 “Agent 受到了某消息影响” 会混淆交付、阅读、采纳与因果影响。

2.2 LLM 自报概率与不确定性

适当的提示格式可以让模型输出具有预测信息的 $P(\text{True})$ 或 $P(\text{IK})$ ，但跨任务校准并不稳定 [7]。后续研究进一步显示，直接询问、答案空间、措辞和其他 prompt 策略都会改变 verbalized confidence 的可靠性 [8,9]。这并不意味着自报量必然无效；它意味着自报量是一种需要按域验证的测量仪器输出，而不是模型内部“真实信念”的透明窗口。

Sampling-based semantic entropy、生成一致性和辅助 confidence predictor 提供了不同的黑盒不确定性信号 [10,11]。SwarmAlpha 不预设自报概率优于这些方法；在 detector 实验中，它们应作为强基线。我们的差异不在于发明一个新的 uncertainty score，而在于规定任意候选 score 在获得控制权限前必须提供何种证据。

2.3 路由、异构协作与 provenance

RouteLLM、FrugalGPT 和 Mixture-of-Agents 已经研究了在质量、成本和模型能力之间分配调用 [12,13]。因此“把多个异构模型放在一起”不是本文的新颖性。更长期的 SwarmAlpha 将考虑当前 claim state、来源相关性和历史验证条件下的边际认知价值，但本文尚不估计这一量。

Provenance 标准区分 entity、activity 与 derivation [14]，为记录来源提供了通用语言；然而来源被记录不等于来源真实，也不等于证据支持命题。本文的 replay 证明 artifact 内部关系可重算，不声称外部时间戳、签名或事实真实性。

2.4 缺口：从观测到控制的资格链

现有工作分别覆盖 debate、confidence、failure taxonomy、routing、proper scoring 与 provenance。尚缺少的是把它们串成一个可证伪的权限问题：提示词条件化报告是否对 nuisance

稳定、是否对已知证据响应、是否对 held-out outcome 提供增量、detector 是否在未参与规则选择的数据上有效，以及随机交付的治理行动是否改善独立结果。SwarmAlpha 将这条链作为统一方法贡献。

3. 研究对象与量的认识论分层

3.1 Claim-relative 状态

设任务注册一个 claim (c), 其 canonical outcome space 为 $(\Omega_c=\{\omega_1,\dots,\omega_K\})$ 。对于 agent (i)、轮次 (t) 与冻结 elicitation contract (e), 系统观测到报告

$$\begin{aligned} & \set{\hat{\mathbf{p}}_{i,c,t}(e)}{\in \Delta^{K-1}}. \end{aligned}$$

帽号是必要的：它表示“在 contract (e) 下观察到的报告”，而不是潜在信念的无偏估计。Contract 至少包含逐字 system/user prompt、public context、该 Agent 的 private view、可见 transcript、canonical option order、模型与版本、temperature、max tokens、response schema、解析器版本和失败政策。改变这些字段可能改变被测对象，因此新版本不能静默继承旧版本的资格。

Claim 由任务拥有，而不是由对话临时创造。Categorical options 必须互斥、穷尽并保持 canonical order; authorized resolver 在所有 measurement response terminal 后才开放 outcome。这样可以避免由最终答案反向改写 claim 或 prompt。

3.2 五层对象

层	例子	数据来源	可以说明	不能说明
测量仪器	prompt、option order、model/config、可见信息	冻结 contract	报告在何种条件下产生	条件变化后仍是同一测量
LLM 自报	message、概率向量、reported evidence	单次模型响应	模型在该条件下生成了什么	内心信念、真实知识、证据真实性
架构遥测	exposure、delivery、observedReportIds、token/call	runtime event	系统实际交付了什么	Agent 注意、理解、采纳或受因果影响
系统派生量	certainty、entropy、margin、JSD、TV、lineage count、pool	冻结公式重算	报告的几何或记录结构	自动具备构念效度、校准或控制价值
结果/控制对象	Brier、ECE、diagnosis、eligible、action state	resolution + policy	在限定设计下评价结果或执行决策	跨域真理、一般治理效果

confidence 一词在本文中不单独使用。若指 $(\max_k \hat{p}_k)$, 写作 **reported certainty**; 若指模型额外输出的自然语言标签, 则写作 **self-reported metacognitive telemetry**; 若指预测正确的经验频率, 则属于 calibration 分析。三者不可互换。

3.3 Evidence 与 lineage

Agent 可以随报告提交 content、relation $\in\{\text{supports, attacks}\}$ 和可选 lineageId。这些都是 reported evidence。系统将 evidence identity、来源引用、verification 和 supersession 作为 append-only events; 原记录不被覆盖。lineageRecordCount=0 只表示“没有合格的 lineage 记录”, 不能解释为该主张没有来源、来源独立或由 Agent 自主产生。外部证据是否真实, 需要单独 oracle 或人类检验。

3.4 Collective state 的地位

群体均值、分歧、共识和 Influence Gini 可由 claim-relative reports 与 exposure graph 派生。它们描述讨论状态, 可用于 secondary prediction 或 mediator analysis, 但默认没有控制权限。共识增长可能来自正确整合, 也可能来自从众; 影响均匀可能改善程序公平, 也可能稀释专家信息。只有其对独立 outcome 的 held-out 增量得到验证后, 才可进入 detector 候选。

4. SwarmAlpha 如何测量

4.1 三个测量阶段的信息防火墙

阶段	模型可见	模型不可见	输出用途
Discussion report	public context; 自己的 private information; 架构实际交付的 public transcript; claim/options	ground truth; resolver outcome; 其他 Agent 未公开的 private view; 未来消息	在线显式报告、讨论文本和 reported evidence
Verification action	public context; claim; 待核验的 public message	所有 Agent private information; ground truth; 替代/正确答案	public-only 的 supported/contradicted/insufficient-evidence verdict
Final private elicitation	public context; 自己的原始 private information; 完成的 public transcript	ground truth; 其他 Agent private view; 正确性反馈	arm-invariant 独立 outcome report, 不再回流讨论

可见性本身进入 artifact。系统记录“消息被放入 prompt”，不把它写成“Agent 阅读并理解”。这种保守表达为以后随机化 exposure、研究传播和信息隔离保留了因果空间。

4.2 Discussion prompt: 逐字仪器

当前 categorical B/G instrument 的 system prompt 是：

You are an analyst in a multi-agent group discussion.
Report your final belief as strict JSON.

User prompt 按以下逐字模板生成，尖括号由冻结 artifact 填充：

Task public context:
<PUBLIC_CONTEXT>

Your private information:
<OWN_PRIVATE_INFORMATION>

Visible discussion transcript:
<TRANSCRIPT_OR_(none)>

Claim <CLAIM_ID>: <PROPOSITION>

Return exactly one strict JSON object with fields: message (string), belief ({kind:'categorical', probabilities:{...}}), evidence (array of {content, relation:'supports'|'attacks', lineageId?}). The probabilities object must contain exactly these canonical options in this order and sum to 1: <OPTION_1 | OPTION_2 | ...>. No other fields.

这个 prompt 同时完成四项操作：限定信息边界；把问题锚定到 task-owned claim；要求 canonical probability vector；把面向群体的 message 与 reported evidence 分开。它也可能诱导格式服从、选项锚定和概率伪精确，因此 prompt hash、option order 和模型配置都属于测量仪器，而不是可忽略的实现细节。

Binary contract 将 belief 改为 {"kind":"binary","probability":0..1}。T arm 使用 plain text，不被解释为概率报告。模型不能添加自由 confidence、隐藏 scores 或额外字段，避免多个同名量并存。

4.3 解析、失败与唯一 terminal record

系统首先保留 raw response，再执行 strict schema validation。Categorical vector 必须恰好覆盖 canonical options，每项是有限的 [0,1] 数，且和为 1；binary probability 必须落在 [0,1]。非法 JSON、字段增删、NaN、未归一化或 option 漂移都不会被修复为“近似合法”。每个注册 request 恰好产生一个 terminal status：

answered | invalid_response | provider_error | timeout |
unavailable | abstained

同一 request 不内部重试。重试会使“第一次失败的困难样本”从观测分布中消失，并把 provider 行为与测量算法混为一谈。若需要新调用，必须注册为新的 replicate，而不是覆盖旧记录。Coverage 的分母始终是注册请求数：

\[
 \text{valid coverage}=\frac{N_{\text{valid reports}}}{N_{\text{registered requests}}},\quad
 \text{pair coverage}=\frac{N_{\text{complete pairs}}}{N_{\text{registered pairs}}}.
\]

4.4 Report、evidence 与 exposure 事件

合法报告被规范化为 claim、agent、round、value、evidence references、timestamp 与 supersedes relationship。Evidence 内容与来源分开 hash；exposure event 记录某个 report 是否被架构交付给某个 Agent 的某轮 prompt。后续 revision 追加新 report，并引用被替代记录，绝不覆写历史。

这使 Belief DAG 成为可重放的“报告关系图”，而不是模型内心状态图。边可以表达时间先后、显式引用、evidence lineage 和 supersession；在没有随机 exposure 或其他识别设计时，边不能被解释为因果影响。

4.5 Final private elicitation

讨论结束后，每个 Agent 收到独立、私密且不回流的 outcome prompt。其关键文本如下：

```
The discussion is complete. This is a private outcome measurement.
Other agents will not see your response, and your response will not
re-enter the discussion. No correctness feedback is available yet.

Public task context:
<PUBLIC_CONTEXT>

Your original private information:
<OWN_PRIVATE_INFORMATION>

Completed discussion transcript:
<PUBLIC_TRANSCRIPT>

Report your final probabilities for every registered claim:
- claimId=<ID>: <PROPOSITION>
  Return a probability for every canonical outcome: <OPTIONS>.
  The probabilities must sum to 1.

Return only one JSON object ... To decline, use {"status":"abstained"}.
Do not include evidence, rationale, confidence labels, scores, or any
additional fields.
```

该 prompt 在各 protocol arm 间逐字一致，只允许自己的原始 private information；resolution 尚未开放。它避免用在线 detector 的同一字段循环评价自身，也避免治理消息直接改变评分器。所有 terminal report 关闭后，authorized resolver 才写入 outcome。

4.6 单报告派生量

对 categorical report ($\hat{\mathbf{p}}$)，定义：

```
\[
\text{certainty}(\hat{\mathbf{p}})=\max_k\hat{p}_k,
\quad
\text{margin}(\hat{\mathbf{p}})=\hat{p}_{(1)}-\hat{p}_{(2)},
\]

\[
H_N(\hat{\mathbf{p}})=-\frac{\sum_k\hat{p}_k\ln\hat{p}_k}{\ln K}.
\]
```

Binary report 令 $\mathbf{p}=(p,1-p)$ ，因而 $\text{certainty}=\max(p,1-p)$ ， $\text{margin}=|2p-1|$ 。这些量只描述报告分布的集中程度。高 certainty 不等于正确、知识充分或证据强；低 entropy 也可能是自信的错误。

4.7 两报告距离与扰动量

在同一 canonical coordinates 上：

```
\[
TV(\mathbf{p},\mathbf{q})=\frac{1}{2}\sum_k|p_k-q_k|,
\]

\[
JSD_2(\mathbf{p},\mathbf{q})=\frac{1}{2}KL_2(\mathbf{p}||\mathbf{m})
+\frac{1}{2}KL_2(\mathbf{q}||\mathbf{m}),\quad \mathbf{m}=\frac{\mathbf{p}+\mathbf{q}}{2}.
\]
```

Base-2 JSD 落在 $[0,1]$ 。小距离说明两次报告接近，却不说明二者正确。Option permutation 必须先按冻结 bijection 映回 canonical order；若映射缺项、重复或 claim 漂移，整个 cell fail closed。Tie 定义为所有最大概率选项的集合，不按显示顺序破平。

4.8 Proper loss 与 calibration

Resolution outcome (y) 开放后, categorical multiclass Brier loss 为

\[
\mathbb{L}_B(\mathbf{p}, y) = \sum_{k=1}^K (p_k - \mathbb{1}[y = \omega_k])^2,
\]

binary 版本为 $((p-y)^2)$ 。Brier 是 single-report proper loss, 但一个 loss 不是 calibration。Calibration 需要许多可比较 claims; ECE 为

\[
ECE = \sum_{b=1}^B \frac{|S_b|}{N} \left| \operatorname{acc}(S_b) - \operatorname{conf}(S_b) \right|,
\]

并依赖 bins、样本选择与 confidence 定义。因此本文同时报告 bin counts、coverage 和 Brier; ECE 仅为 secondary characterization, 不是 Gate primary metric。

4.9 群体聚合与来源折扣

最透明的 operational outcome 是对合法 final reports 等权 linear pool:

\[
\bar{\mathbf{p}}_c = \frac{1}{n_c} \sum_{i \in A_c} \hat{\mathbf{p}}_{\{i, c\}^{\text{final}}}.
\]

所有注册 Agent 保留在 missingness 分母, 只有 answered reports 进入数值 pool。更复杂的 lineage-capped 或 reputation-weighted pool 是不同机制, 必须携带 method ID、source report IDs 和单独验证; 不能被描述为 “真实群体信念”。

5. 从测量资格到控制权限

5.1 四级资格

级别	必须证明	获得的权限	仍然禁止
Q0 structural-qualified	request 到唯一 terminal record 闭合; schema/hash/replay 合法	描述 coverage、失败和报告几何	预测、检测、治理
Q1 response-qualified	对语义等价 nuisance 稳定; 对已知证据方向/强度有非平凡正确响应	detector development、secondary trajectory analysis	自动触发控制; 称为 latent belief
Q2 outcome-qualified	对 held-out authorized outcomes 相对冻结 baseline 有 proper-loss 增量	作为 outcome/预测 instrument	跨域外推; 治理有效
Q3 transport-characterized	跨模型、任务族、K、prompt/config stratum 报告适用与失效域	限定域复用	“普适测量”

Q0 不蕴含 Q1, Q1 不蕴含 Q2。Gate 是非补偿式: 极高 coverage 不能抵消 evidence response 失败, 良好 repeat stability 不能抵消 outcome 反预测。资格按 instrument × belief kind × K × model/config × task family 版本化。

5.2 扰动家族各自检验什么

- Exact repeat: 除独立 provider call identity 和预注册 seed 外完全相同, 估计生成噪声; 不替代语义稳定性。
- Semantic paraphrase: 只改表述, 不改 claim、facts、roles、options 或 evidence relation。人工 accepted semantic review 是必要条件; 自动相似度只能筛查。
- Option permutation: 只改变显示顺序, 通过冻结 bijection 检验 coordinate equivariance。
- Evidence direction: 用受控生成机制提供支持与反向证据, 检验 $(p(y^*))$ 是否按预期方向改变。
- Evidence strength: 至少三阶预注册 ladder, 检验 Spearman response、相邻等级 violation 和 response slope。自然语言材料不能事后主观标 “强证据”。
- Information add/remove: 改变了认知条件, 不属于 nuisance; 用于研究信息整合, 不进入 paraphrase stability。

Primary uncertainty 以 leakageGroupId/baseSemanticTaskRef 聚类。报告行、同一 run 的多个 Agent、同一 base task 的 variants 都不是独立样本。任何需要 bootstrap Gate 的分析至少需 20 个独立 cluster；不足时输出 insufficient_cluster_support。

5.3 从 Q1 到 detector 仍需第二道门

Q1 只说明 instrument 对扰动具有合格响应，不说明某个 threshold 能预测错误。Detector 必须在与规则选择分离的 held-out data 上与 uniform、climatology、sampling consistency/semantic entropy 等基线比较，并报告 discriminative performance、coverage、proper-loss increment 和 domain hash。阈值满足 $\text{certainty} > 1/K$ 只是类型合法性，不是经验校准。

6. 治理作为被测对象

6.1 两种随机化不能混淆

protocol-arm assignment 在 run 级分配 T/B/G 等交互协议；governance-action assignment 只在 G 内对 eligible event 分配 apply、sham 或 holdout。前者估计协议整体效果，后者估计一次治理行动的局部 ITT 效果。两者的 unit、seed、概率向量和 estimand 分开冻结。

当前 candidate rule 是“高 reported certainty 且缺少合格 lineage 时请求独立验证”。这只是候选机制。探索结果显示 $\text{certainty} \geq 0.7$ 初步反预测，因此该规则不能因代码已实现就获得 confirmatory 控制权限。

6.2 Apply、sham 与 holdout

- Apply: 调用独立 verifier。Verifier 只看 public context、claim 和目标 public message；若公开材料不足，返回 insufficient_evidence；不得猜正确或替代答案。
- Sham: 执行预算和注意力相近的 provider call，但明确禁止评估 claim，不向 transcript 引入任务证据。
- Holdout: eligible 事件不交付 action，保留自然反事实。

Apply 的代表性 V2 prompt 为：

```
Task public context:
<PUBLIC_CONTEXT>

Claim <ID>: <PROPOSITION>

Public message to verify:
<TARGET_PUBLIC_MESSAGE>

Judge only whether the public context supports or contradicts the public
message. If the public context is underdetermined, use
insufficient_evidence. Do not identify, recommend, or guess an alternative
or correct answer. Return exactly one strict JSON object with fields:
evidenceScope (exactly "public_only"), verdict (exactly "supported",
"contradicted", or "insufficient_evidence"), and explanation (non-empty
string). No other fields.
```

该 action 的价值必须由之后的 final outcome 判断。Verifier 输出 supported 不是 task truth，delivery completed 也不是 Agent 采纳。

6.3 治理质量的主 estimand

令 (A_j) 是 eligible event 的随机 action， (Y_j) 是对应 run 的 final pooled operational Brier。局部 primary estimand 为

$$\tau_{\{A-H\}} = E[Y_j \mid A_j = \text{apply}] - E[Y_j \mid A_j = \text{holdout}],$$

lower is better。Sham 用于区分信息内容与额外 attention/compute。分析遵循 ITT：投递失败、invalid final report 和 abstention 不从分母消失；推断按 task/leakage cluster，而不是按 report 行。

治理 scorecard 分开报告决策质量、calibration/coverage、错误传播、信息/影响分布、成本/延迟和安全/审计。共识率、Influence Gini、recovery time 与 verifier verdict 都是 mediator 或 secondary outcome，不能替代

(tau)。

7. 实现与重放边界

V6 将 study contract、task manifest、primary assignment、arm implementation binding、report/evidence/exposure events、diagnosis、eligible decision、action assignment、delivery transition、final elicitation 和 operational outcome 串成 authority chain。确定性对象使用 canonical serialization 与内容 hash；registry 和 policy 以精确版本引用；builder 以批次原子性追加事件，seal 后不可修改。

sealed_decision_replay_verified 意味着：给定 artifact 和冻结 rule registry，结构关系、随机分配与派生决策可重算一致。它不意味着数据在仓库外从未被替换，不证明 provider 真正执行了某次调用，也不证明 reported evidence 为真。外部真实性还需要 detached commitment、可信时间戳或签名；本文不使用 tamper-proof。

8. 探索性证据

8.1 执行完整性

冻结实验包含 20 个 HiddenBench 数据投影任务，每题 B arm 两次、G arm 两次，共 80 runs。Provider 为 deepseek-chat，temperature=0；Stage-2 预注册 apply/sham/holdout 概率为 0.50/0.25/0.25。实际完成 80/80 runs，产生 948 次 provider calls、1,005,975 tokens。没有内部 retry、补样本、换任务或重抽 seed。80 个 raw-run artifact 均通过 verifyRawRunData，状态为 sealed_decision_replay_verified。

这些数字建立了执行和内部重放完整性，不建立 prompt instrument 的测量效度。特别是原计划 token estimate 低估实际用量约 70 倍；虽然硬预算未越界，后续预算必须使用本次真实 usage 分布，而不能复用旧公式。

8.2 Coverage 与 exact-repeat

在未受治理处理污染的 B-arm round-1 中，共注册 154 个显式报告请求：142 valid、11 invalid、1 unavailable，valid coverage=0.9221。Exact-repeat 注册 77 个 task-role pairs，66 complete，pair coverage=0.8571。Complete pairs 的 base-2 JSD median=0.0050、P90=0.1348，tie-aware argmax agreement=0.7727。

Median 显示多数完整 pair 的报告接近；P90、argmax 与 missing pairs 又说明稳定性并非一致。更重要的是，两次 prompt 逐字相同，因此这里只估计 repeat stability，不能说明 semantic paraphrase robustness、option-order equivariance 或 evidence responsiveness。

8.3 Proper loss、calibration 与候选 detector

K=3 的 121 个合法 round-1 报告 mean multiclass Brier=0.9275，高于均匀报告的 0.6667；K=4 的 21 个报告 mean Brier=1.0776。K=3 的固定 bins ECE=0.4046。在 [0.9,1.0] certainty bin 中，平均 certainty 为 0.956，而经验准确率只有 0.125。

预置 certainty>=0.7 flag 在 K=3 上的 (P(errormid flagged)=0.7436)，未 flag 为 0.4884；flagged-minus-unflagged Brier gap=+0.4217。也就是说，该候选信号在当前样本上初步反预测。这个结果不是“LLM 永远越自信越错”，却足以阻止该 threshold 获得 detector/control 权限。它也说明结构化 JSON 和低 repeat JSD 不会自动带来 outcome validity。

8.4 随机治理结果：DEFER

40 个 G runs 中有 26 个 eligible events：apply=17、sham=7、holdout=2，另有 14 个 ineligible。Apply 的 verifier verdict 为 insufficient_evidence 12、supported 4、contradicted 1。按冻结 primary estimand，naive apply-minus-holdout Brier difference 为 -0.2358，10,000 次 task-cluster bootstrap median=-0.2081，95% interval [-1.2626,+0.7565]，valid fraction=0.8775。

这些方向数不作效果解释。冻结停止规则要求 holdout 数和独立 cluster 均至少为 5, bootstrap valid fraction 至少 0.95; 三项均未满足。因此 primary 状态是 DEFER_INSUFFICIENT。这既不是治理有效的证据, 也不是治理无效的证据。方法贡献在于没有用方向有利的 naive difference 绕过样本不足。

9. 形成 AAMAS 论文所需的下一步证据

第一优先级不是继续添加 schema, 而是完成 Measurement Validity pilot。至少 20 个独立 leakage/base-task clusters 应覆盖 exact repeat、人工审核的 semantic paraphrase、option permutation、受控 evidence direction 和三阶 evidence strength。分析冻结 coverage、JSD/TV、directional shift、strength monotonicity、signal-to-noise ratio 与 held-out delta Brier; 任何 Gate 失败都保留为失败域。

第二步是在独立 development/hold-out split 上验证 detector。比较 reported certainty、margin、entropy、lineage、sampling consistency、semantic entropy 和简单 task-family baseline。仅在 held-out predictive increment、coverage 与 transport domain 均合格时冻结 threshold。

第三步才是治理主实验。它需要增加 holdout 概率或 eligible 样本, 使 apply/sham/holdout 在至少 20 个独立 task clusters 上有支持; 同时加入 compute-matched 单 Agent、self-consistency、majority vote、普通 debate、belief-state-only 与治理臂。Primary 只看 independent pooled proper loss; accuracy、cascade size、recovery time、Influence Gini、abstention、calls/tokens 为 secondary scorecard。

10. 上限: 异构智能治理与社会热力学

10.1 异构智能治理

SwarmAlpha 的中期对象可以从 LLM Agent 扩展到模型、检索器、工具、人类和组织身份组成的异构智能资源。此时问题不是“哪个模型 benchmark 更高”, 而是当前证据状态下再调用资源 (r) 能带来多少增量决策价值。候选 Marginal Cognitive Value 可写为

$$\begin{aligned} \backslash[\\ \text{MCV}(r|\text{mid } s) &= E[L(Y, \hat{p}_s) - L(Y, \hat{p}_{\{s+r\}})] | \text{mid } s] \\ &= -\lambda_{c_r} C_r - \lambda_{t_r} T_r - \lambda_{\rho_r} R_r, \\ \backslash] \end{aligned}$$

其中 (s) 是可审计 claim state, (C,T,R) 分别为成本、延迟和来源相关风险。该式目前是 DESIGN INTENT; 在没有随机或可识别的 resource assignment、held-out outcomes 和跨模型复现前, 不称为已估计量。“正交智能”也应操作化为条件增量而不是输出表面多样性。

10.2 社会热力学没有被废弃

旧稿试图用温度、熵、自由能等宏观量解释群体演化。问题不在这个愿景太大, 而在微观态尚未取得测量资格。本文建立的 claim-relative reports、exposure、lineage 和 action events 为宏观理论提供更干净的基础。后续证据应分四级:

- ST-1 预测: 预注册宏观统计量能否在 held-out runs 预测 error cascade 或 recovery;
- ST-2 响应: 随机改变 exposure、verification 或 information access 后, 宏观量是否按预期方向变化;
- ST-3 缩放: 规律是否随 Agent 数、网络拓扑、模型异质性和任务族保持可描述的尺度关系;
- ST-4 理论: 在前三层成立后, 再提出守恒、临界点、相变或自由能类统一理论。

因此, 当前工作更像为“社会热力学”建立合格的微观测量, 而不是放弃它。没有证据时, 热力学术语只能作为假设, 不能作为解释真实结果的定律。

ST-1

10.3 局限

当前自然任务来自 HiddenBench 数据投影, 主要为 K=3/K=4 categorical claims; 真实运行只使用一个 provider/model stratum。Measurement Validity 的真实 paraphrase 和 controlled-evidence sealed result 尚未完成。报告仍是 prompt-induced 行为, 不是 latent belief。Evidence provenance 主要证明记录关系, 不证明外部事实。Final pool 使用等权规则, 未验证 reputation 权重。治理 holdout

过少，无法估计效果。外部 commitment、跨组织身份、Web3 stake/penalty 和在线 MCV 均未实现。

11. 结论

多智能体治理的薄弱环节往往不是缺少又一个干预，而是用于触发干预的量没有被验证。SwarmAlpha 把 LLM 自报概率明确为提示词条件化观测，把公式派生量限定为描述，把 exposure 与采纳分开，并用 Q0--Q3、held-out detector 和随机 action--outcome 链逐级授予权限。80-run 探索实验说明这条链可执行、可重放，也说明可重放并不等于有效：候选 certainty threshold 初步反预测，治理效果因样本不足被判为 DEFER。

近期论文的目标不是宣称已经解决认知治理，而是证明“何种信号有资格参与治理”可以被严谨地提出、失败并复现。完成 measurement pilot、detector held-out validation 与足量 compute-matched 随机治理实验后，这条方法链才可能支撑 AAMAS 长文；异构智能治理和社会热力学则在其上获得可持续的研究上限。

附录 A：完整提示词族与配置

A.1 Discussion system prompt

You are an analyst in a multi-agent group discussion. Report your final belief as strict JSON.

A.2 Categorical discussion user prompt

见正文 4.2。生产配置冻结 modelRef、temperature、maxTokens、response contract、request ID 和 prompt hash；当前探索配置 discussion temperature=0、maxTokens=768。

A.3 Binary discussion response contract

Return exactly one strict JSON object with fields: message (string), belief ({kind:'binary', probability: 0..1}), evidence (array of {content, relation:'supports'|'attacks', lineageId?}). No other fields.

A.4 Verification V2 system prompt

You are an independent verifier.

User prompt 见正文 6.2。探索配置 verification temperature=0、maxTokens=256。

A.5 Sham prompt

System: You are executing a matched process-control call; provide no task evidence.

User: This is a matched process-control request.
Do not assess any claim, message, evidence, or likely answer.
Return exactly one strict JSON object with one field: acknowledgment (string). No other fields.

A.6 Final private elicitation

见正文 4.5。探索配置 final temperature=0、maxTokens=256。该 prompt 各臂相同，不展示 ground truth，不允许 rationale/evidence/confidence labels，响应不回流 discussion。

附录 B：量的快速注册表

量	公式/记录	角色	最小资格	典型误用
reported probability	($\hat{p}$) 或 ($\hat{\mathbf{p}}$)	LLM 自报观测	Q0 描述; Q1/Q2 才扩权	称作内心信念
reported certainty	($\max p_k$)	派生集中度	detector 需 held-out valid	直接当正确概率
normalized entropy	($-\sum \text{pln } p/\text{ln } K$)	派生分散度	同上	当知识/无知真值
margin	($p_{(1)}-p_{(2)}$)	派生决断度	同上	跨 K 直接比较
TV/JSD	两报告距离	稳定/扰动分析	canonical mapping	小距离=正确
Brier	resolved proper loss	outcome	authorized resolution	单样本=calibration

量	公式/记录	角色	最小资格	典型误用
ECE	分箱校准误差	secondary calibration	足量同域 claims	不报 bins/coverage
lineage count	合格来源记录数	provenance 描述	source validation	0=没有来源/独立
exposure	prompt 实际交付 event	架构遥测	runtime audit	等同注意/采纳/因果
consensus/Gini	群体派生描述	mediator/secondary	独立预测验证	等同质量/公平

参考文献

[1] Du, Y. et al. Improving Factuality and Reasoning in Language Models through Multiagent Debate. ICML, 2024. [2] Smit, A. et al. Should We Be Going MAD? A Look at Multi-Agent Debate Strategies for LLMs. ICML, 2024. [3] Li, Y., Naito, T., and Shirado, H. HiddenBench: Assessing Collective Reasoning in Multi-Agent LLMs via Hidden Profile Tasks. 2025. [4] Chen, J., Saha, S., and Bansal, M. ReConcile: Round-Table Conference Improves Reasoning via Consensus among Diverse LLMs. ACL, 2024. [5] Cemri, M. et al. Why Do Multi-Agent LLM Systems Fail? 2025. [6] Li, Y. et al. Improving Multi-Agent Debate with Sparse Communication Topology. Findings of EMNLP, 2024. [7] Kadavath, S. et al. Language Models (Mostly) Know What They Know. 2022. [8] Tian, K. et al. Just Ask for Calibration: Strategies for Eliciting Calibrated Confidence Scores from Language Models Fine-Tuned with Human Feedback. 2023. [9] Yang, A. X., Tsai, M.-H., and Yamada, M. On Verbalized Confidence Scores for LLMs. 2025. [10] Kuhn, L., Gal, Y., and Farquhar, S. Detecting Hallucinations in Large Language Models Using Semantic Entropy. Nature, 2024. [11] Xiao, C. et al. The Consistency Hypothesis in Uncertainty Quantification for Large Language Models. UAI, 2025. [12] Ong, I. et al. RouteLLM: Learning to Route LLMs with Preference Data. ICLR, 2025. [13] Wang, J. et al. Mixture-of-Agents Enhances Large Language Model Capabilities. 2024. [14] W3C. PROV-DM: The PROV Data Model. W3C Recommendation, 2013.